



# Entrega Final: Relatório de Implantação dos agentes inteligentes na solução: **Plataforma de Análise de Notas Fiscais SMART Financial Solutions**

**Github do Grupo:** [https://github.com/gabryel-barboza/smart\\_financial\\_solutions](https://github.com/gabryel-barboza/smart_financial_solutions)

**Grupo:** Grupo Comunicação Integrantes:

Nome	E-mail
Rosenildes Melo	<a href="mailto:rosenildesmelo@gmail.com">rosenildesmelo@gmail.com</a>
Luciano Cyllio	<a href="mailto:cyllio@gmail.com">cyllio@gmail.com</a>
Luis Gustavo	<a href="mailto:eng.gustavo90lima@gmail.com">eng.gustavo90lima@gmail.com</a>
Thiago Araújo	<a href="mailto:thiagojerem@gmail.com">thiagojerem@gmail.com</a>
Gabryel Barbosa	<a href="mailto:gabrielbarbosa.alternativa@gmail.com">gabrielbarbosa.alternativa@gmail.com</a>
Thais Petrin	<a href="mailto:tha.petrin@gmail.com">tha.petrin@gmail.com</a>
Flavio Pereira	<a href="mailto:flavupereira@gmail.com">flavupereira@gmail.com</a>

# Relatório Executivo: Smart Financial Solutions v2.0

## Plataforma de Análise Fiscal com Inteligência Artificial e RAG

### 1. Sumário Executivo

O **Smart Financial Solutions** é um sistema inteligente de análise financeira projetado para facilitar a compreensão de dados de forma rápida e conversacional. A solução opera por meio de uma equipe de assistentes de Inteligência Artificial (IA) que colaboram para processar informações complexas. A arquitetura é dividida em um serviço de processamento robusto (o "cérebro") que executa as análises e uma interface de conversação amigável (o "rosto") para a interação direta do usuário. O conjunto completo é empacotado para instalação e execução simplificada utilizando contêineres Docker.

Este projeto permite aos usuários realizar tarefas financeiras complexas conversando com o sistema. As funcionalidades principais incluem a **Análise de Dados Simples**, onde o usuário pode enviar arquivos (como planilhas) e solicitar resumos ou tendências à IA. Além disso, o sistema oferece **Busca Inteligente** sobre documentos (incluindo XMLs), encontrando informações relevantes mesmo em textos menos claros. Ao final do processamento, o sistema pode gerar **Relatórios detalhados em PDF** e, se desejado, enviá-los por e-mail, acompanhados de **Visualização Automática** com gráficos exibidos diretamente na tela de chat para facilitar a compreensão dos resultados.

### 2. Descrição da Solução

A **Plataforma de Análise de Notas Fiscais SMART v2.0** é um sistema automatizado e inteligente que revoluciona a maneira como as empresas gerenciam, extraem valor e garantem conformidade de seus dados fiscais. A solução abrange desde o upload e a análise automatizada de documentos fiscais até a geração de relatórios dinâmicos, com um diferencial estratégico: a capacidade de realizar **buscas semânticas** em toda a base de documentos fiscais armazenados.

#### Frontend Interativo (React / TypeScript)

O frontend é um **single-page application (SPA)** interativo que provê a experiência conversacional e de upload.

Funcionalidade	Detalhe Técnico
Interface Conversacional	Chatbot que responde perguntas, aceita upload de arquivos e gerencia o histórico de mensagens.
Gerenciamento de Estado	Utiliza Context API e ServerContext para gerenciar o estado da aplicação.
Renderização de Gráficos	O frontend recebe o ID para busca de gráficos do backend, requisita o JSON do gráfico resultante e renderiza o gráfico de forma dinâmica com Plotly.js.
Upload Assíncrono	Gerencia o upload de arquivos de dados (CSV/XLSX/ZIP) e imagens (JPEG, PNG, TIFF, BMP), utilizando o canal WebSocket para mostrar o status de processamento em tempo real.
Configuração Dinâmica	A ConfigPage permite o mapeamento e alteração dos modelos LLM (ex: llama3-8b) para tarefas/agentes específicas (SUPERVISOR, DATA ANALYST), enviando a configuração para o backend.

## 2.1. Principais Funcionalidades

A plataforma oferece um conjunto abrangente de funcionalidades que cobrem todo o ciclo de vida da gestão fiscal:

- **Ingestão Inteligente de Documentos Fiscais:** Processamento automatizado de XMLs de notas fiscais (NFe, NFCe, CTe) com extração e validação de campos críticos.
- **Armazenamento Vetorial com RAG:** Transformação de documentos fiscais em embeddings vetoriais para busca por similaridade semântica.
- **Busca Semântica Avançada:** Consultas em linguagem natural sobre toda a base de documentos fiscais, retornando resultados relevantes mesmo sem correspondência exata de palavras-chave.
- **Análise Estatística de Dados:** Geração de gráficos interativos, detecção de outliers, análise de correlação e clustering com K-Means.
- **Validação e Conformidade Fiscal:** Verificação automática de campos obrigatórios, validação de CNPJs, datas e valores.
- **Geração de Relatórios Profissionais:** Criação de relatórios em PDF com insights fiscais e envio automatizado por e-mail via SMTP.
- **Chat Inteligente com Contexto:** Interação em linguagem natural com acesso ao histórico de conversação e dados fiscais armazenados.
- **Isolamento Multi-Tenancy:** Garantia de segurança e privacidade com isolamento completo dos dados de cada usuário.

## 2.2. Arquitetura RAG Implementada

A arquitetura de **Retrieval-Augmented Generation** permite que os agentes de IA accessem informações específicas dos documentos fiscais armazenados, combinando a capacidade de recuperação de informações com a geração de respostas contextualizadas.

### Componentes principais da arquitetura RAG:

- 1 **Modelo de Embeddings:** FastEmbed com modelo [paraphrase-multilingual-MiniLM-L12-v2](#) (384 dimensões)
- 2 **Vector Database:** Qdrant com algoritmo HNSW para busca aproximada de vizinhos mais próximos (ANN)
- 3 **Isolamento de Dados:** Índice de payload com campo [metadata.user\\_id](#) configurado como tenant
- 4 **Busca por Similaridade:** Cálculo de distância cosine entre vetores de query e documentos
- 5 **Contextualização:** LLMs utilizam os documentos recuperados para gerar respostas precisas e contextualizadas.




Figura 1: Diagrama do fluxo de interação com o banco de dados vetorial.

### 3. PÚBLICO-ALVO

A aplicação é ideal para **empresas de todos os portes** que buscam otimizar sua gestão fiscal, de compliance e de auditoria. Ela se destina especialmente a:

- **Departamentos Fiscais e Contábeis:** Que necessitam de automação na validação e análise de notas fiscais.
- **Empresas de Auditoria:** Que realizam conferências cruzadas entre bases de dados fiscais e operacionais.
- **Gestores Financeiros:** Que precisam de insights rápidos sobre despesas, receitas e impostos.
- **Empresas com Alto Volume de Documentos Fiscais:** Que se beneficiam da busca semântica para localizar informações específicas rapidamente.
- **Organizações que Buscam Conformidade Fiscal:** Que necessitam de validação automática e rastreabilidade de documentos.

## 4. Instalação e Inicialização

Toda a aplicação é empacotada e executada através do **Docker Compose**, garantindo um setup rápido e confiável. Porém, o usuário tem a opção de clonar o projeto e inserir os comandos manualmente para colocar o projeto em execução.

### 4.1. Pré-requisitos

Para executar este projeto, você só precisa ter o **Docker** instalado na sua máquina e ter no mínimo **4 GB de armazenamento livre** para a aplicação.

**Considerações Importantes:** na primeira execução do projeto, todas as imagens e dependências serão baixadas para o seu funcionamento. Esse processo, a depender da conexão do usuário, pode levar um tempo médio de **10 - 20 min**. Em execuções posteriores, as dependências já foram cacheadas e a execução é mais rápida.

### 4.2. Configuração do Ambiente

- **Clone o repositório:**

```
git clone https://github.com/gabryel-barboza/smart_financial_solutions.git
```

```
cd smart-financial-solutions
```

Uma alternativa mais simples é clicar em <> **Code** e baixar o ZIP do projeto, com a desvantagem de não sincronizar com o repositório remoto.

- **Configurar variáveis de ambiente:**

Copie o arquivo de exemplo .env.example e renomeie-o para .env. Preencha-o com suas credenciais, adicione uma chave de API do LangSmith para serviço de tracing dos agentes. Os valores padrões são o suficiente para o projeto funcionar.

```
cp .env.example .env
```

**O arquivo .env, no mínimo:**

```
# Credenciais para servidor de email (SMTP Gmail)
```

```
SENDER_EMAIL="seu_email@gmail.com"
SENDER_PASSWORD="sua_credencial_de_app"

# Configurações do Qdrant
QDRANT_URL="http://qdrant:6333"

# Configurações da conexão com banco de dados
DATABASE_URI="sqlite:///databases/db.sqlite"

# Configurações do Langsmith para rastreamento das LLMs (Opcional)
LANGSMITH_TRACING=true
LANGSMITH_API_KEY="api_key"

LANGSMITH_PROJECT="smart_financial_solutions"
```

#### 4.2.1. Inicialização da Aplicação Manual

Se optar pela inicialização manual, o projeto será executado em modo de desenvolvimento. A conexão com Qdrant Vector Store deve ser modificada para a sua instância, provavelmente no Qdrant Cloud.

Você precisará ter o **Node.js-20** e o **Python-3.12** instalados. Para começar acesse o diretório raiz do projeto e abra terminais nos diretórios frontend e backend.

- **Windows:** Abra um terminal pesquisando por CMD na barra de endereço (C:\user\ ) na pasta do projeto e pressionando ENTER ou pesquisando por CMD no menu Windows e navegando até o projeto com cd pasta1\pasta2\pasta3.
- **Linux:** Abra um terminal de preferência e navegue com o comando cd diretorio1/diretorio2/diretorio3.

**Insira o seguinte comando no diretório frontend:**

```
npm run dev
```

**No diretório backend, insira os comandos a seguir no terminal:**

```
# crie um ambiente virtual com:
python -m venv .venv
# ou outro gerenciador de ambientes virtuais e ative-o com:
```

```
.venv/Scripts/activate # Windows  
source .venv/bin/activate # Linux  
  
# Faça a instalação das dependências com:  
pip install -r requirements.txt  
  
# Execute o projeto com  
  
fastapi dev src/main.py
```

Acesse os serviços nas rotas retornadas pelo terminal.

#### 4.2.2 Inicialização da Aplicação com Docker

Para subir todos os serviços (**Frontend, Backend FastAPI e Qdrant**), execute o comando adiante no diretório raiz. Tenha certeza de estar no diretório que contém o arquivo compose.yml:

```
docker compose up --build
```

O argumento opcional --build garante que quaisquer atualizações no código sejam incorporadas nos containers, necessário quando houver mudanças no projeto.

Serviço	URL
Frontend (React)	<a href="http://localhost:8080">http://localhost:8080</a>
API Docs (FastAPI - Swagger UI)	<a href="http://localhost:8000/api/docs">http://localhost:8000/api/docs</a>
Qdrant Dashboard	<a href="http://localhost:6333/dashboard">http://localhost:6333/dashboard</a>

## 5. Justificativa e Geração de Valor

O cenário atual de gestão fiscal é marcado por ineficiências, complexidade da legislação tributária brasileira e fragmentação de dados. A dependência de processos manuais resulta em erros, inconsistências e um alto custo operacional. A plataforma SMART v2.0 aborda diretamente essas dores, oferecendo uma solução que vai além da automação básica.

## 5.1. Benefícios Estratégicos

Os principais benefícios e fontes de valor incluem:

- **Eliminação do Trabalho Manual:** Redução drástica de erros e do tempo gasto com tarefas repetitivas de digitação, validação e busca de documentos.
- **Extração Precisa de Informações:** Agentes de IA garantem acurácia e consistência na extração de dados de documentos fiscais estruturados e não estruturados.
- **Busca Inteligente e Rápida:** Localização instantânea de informações fiscais através de consultas em linguagem natural, sem necessidade de conhecer a estrutura exata dos dados.
- **Validação Instantânea e Padronizada:** A validação das informações fiscais é realizada de forma rápida e uniforme, minimizando riscos de não conformidade.
- **Auditoria Cruzada Automatizada:** Capacidade de correlacionar dados fiscais com outras bases internas da empresa (estoque, financeiro, RH).
- **Redução de Tempo e Custos:** Liberação de equipes para focar em atividades de maior valor agregado, impulsionando a produtividade.
- **Aceleração da Auditoria e Conformidade:** Visibilidade e controle aprimorados, garantindo a aderência às regulamentações fiscais e mitigando riscos de multas.
- **Escalabilidade e Segurança:** Arquitetura multi-tenancy permite atender múltiplos clientes com isolamento completo de dados.

## 5.2. Retorno sobre Investimento (ROI)

A implementação da plataforma SMART v2.0 gera retorno mensurável em múltiplas dimensões:

Métrica	Antes da Plataforma	Com a Plataforma	Ganho
<b>Tempo de Validação de NF</b>	5-10 min/documento	30 seg/documento	<b>90% de redução</b>
<b>Busca de Informações Fiscais</b>	15-30 min/consulta	1-2 min/consulta	<b>95% de redução</b>
<b>Erros de Digitação</b>	5-10% dos documentos	< 0.1%	<b>99% de redução</b>
<b>Tempo de Auditoria</b>	40-60 horas/mês	10-15 horas/mês	<b>75% de redução</b>
<b>Custo Operacional</b>	Alto (processos manuais)	Baixo (automatizado)	<b>60-70% de redução</b>

## 6. Detalhamento Técnico do Desenvolvimento

A seguir, apresentamos um detalhamento técnico da solução desenvolvida, incluindo a arquitetura do software, a implementação dos agentes de IA, as ferramentas utilizadas, as validações criadas e os relatórios gerenciais gerados.

### 6.1. Stack Tecnológica Completa

#### Backend

- **Framework:** FastAPI 0.119.0 (assíncrono)
- **Linguagem:** Python 3.12
- **Orquestração de IA:** LangChain 0.3.19 + LangGraph
- **Vector Database:** Qdrant (cliente assíncrono)
- **Modelo de Embeddings:** FastEmbed com paraphrase-multilingual-MiniLM-L12-v2
- **Provedores de LLM:**
  - Google Gemini 2.5 Flash e Pro (langchain-google-genai 2.1.12)
  - Groq com Llama 4 Maverick/Scout e Qwen 3 (langchain-groq 0.3.8)
  - Suporte para OpenAI via LangChain
- **Análise de Dados:** Pandas 2.3.2, NumPy 2.3.3
- **Visualização:** Plotly 6.3.0
- **Machine Learning:** Scikit-learn 1.7.2 (K-Means clustering)
- **OCR:** Pytesseract 0.3.13
- **Banco de Dados Relacional:** SQLite com SQLAlchemy 2.0.43
- **Geração de PDF:** markdown-pdf 1.10
- **Envio de E-mail:** SMTP (smtplib) com suporte a Gmail
- **Servidor ASGI:** Unicorn 0.35.0

#### Frontend

- **Framework:** React 18
- **Linguagem:** TypeScript
- **Build Tool:** Vite
- **Visualização:** Plotly.js
- **Servidor Web:** Nginx (em produção)
- **Novos Componentes:** UserInput para identificação de usuário

#### Infraestrutura

- **Orquestração:** Docker Compose (3 serviços)
- **Tracing de LLM:** LangSmith
- **Persistência:** Volumes Docker para Qdrant e banco de dados

## 6.2. Arquitetura de Deployment Atualizada

A aplicação é orquestrada com **Docker Compose**, incluindo o serviço Qdrant para armazenamento vetorial, a API em FastAPI e a interface gráfica em React.

### Serviços Docker:

- 6 **Frontend (Nginx:80)**: Interface React com novos componentes para identificação do usuário
- 7 **Backend (FastAPI:8000)**: API assíncrona com integração ao Qdrant
- 8 **Qdrant (6333)**: Vector database com HNSW para busca ANN

### Volumes Persistentes:

- qdrant\_storage: Armazenamento dos vetores e índices
- fastembed\_cache: Cache dos modelos de embeddings
- databases/: Banco de dados SQLite

## 6.3. Envio de Relatórios via SMTP

A plataforma utiliza o protocolo **SMTP** para envio automatizado de relatórios PDF por e-mail. A implementação utiliza a biblioteca nativa smtplib do Python, com suporte específico para Gmail.

### Fluxo do Relatório PDF:

- 9 O **Report Generation Agent** usa a ferramenta create\_and\_send\_report para criar um arquivo PDF a partir de conteúdo Markdown.
- 10 Após a criação do PDF, o agente utiliza a função send\_report que estabelece uma conexão SMTP com o servidor Gmail (smtp.gmail.com:587).
- 11 O e-mail é enviado com o PDF anexado para o destinatário especificado pelo usuário.
- 12 A função retorna confirmação de sucesso ou mensagem de erro detalhada.

### Configuração Necessária:

Para utilizar o Gmail como servidor SMTP, é necessário:

- 13 Habilitar a autenticação de dois fatores na conta Google
  - 14 Gerar uma "Senha de App" específica para a aplicação
  - 15 Configurar as variáveis SENDER EMAIL e SENDER PASSWORD no arquivo .env
-

## 7. Agentes de Inteligência Artificial

A inteligência da aplicação é distribuída em um **sistema multiagente**, onde cada agente possui uma especialização e um conjunto de ferramentas para cumprir suas tarefas. A orquestração é liderada por um agente Supervisor, que delega o trabalho para os agentes apropriados.




Figura 2: Diagrama com o fluxo de orquestração dos agentes.

### 7.1. Supervisor Agent (Smartie)

**Responsabilidade:** Atua como o orquestrador central. Ele recebe todas as solicitações do usuário, interpreta a intenção e delega a tarefa para o agente especialista mais adequado.

**Modelo LLM:** Qwen 3 32B (Groq) ou Gemini 2.5 Flash (Google)

#### Ferramentas:

- use\_agent\_tool: Invoca outros agentes especializados
- get\_current\_datetime: Fornece data e hora atual

## **Workflow:**

- 16 Recebe a solicitação do usuário
- 17 Analisa a intenção e o contexto
- 18 Identifica o agente especialista mais adequado
- 19 Delega a tarefa via use\_agent\_tool
- 20 Recebe o resultado e formata a resposta final

## **7.2. Data Engineer Agent - Especialista em Extração Fiscal**

**Responsabilidade:** Especializado em extrair, validar e armazenar dados de documentos fiscais brasileiros (XMLs de NFe, NFCe, CTe) no banco de dados vetorial Qdrant.

**Modelo LLM:** Gemini 2.5 Flash (Google)

### **Ferramentas:**

- qdrant\_data\_insert: Insere dados validados no Qdrant com embeddings
- extract\_data: Busca documentos por similaridade semântica

### **Campos Fiscais Extraídos:**

<b>Campo XML</b>	<b>Descrição</b>	<b>Validação</b>
<u>chNFe</u>	Chave de Acesso da NFe (44 dígitos)	Formato numérico, 44 caracteres
<u>CNPJ (Emitente/Destinatário)</u>	CNPJ das partes envolvidas	14 dígitos numéricos
<u>dhEmi</u>	Data e Hora da Emissão	Formato ISO 8601
<u>vNF</u>	Valor Total da Nota Fiscal	Numérico, maior que zero
<u>natOp</u>	Natureza da Operação	Texto descritivo
<u>xProd</u>	Descrição do Produto/Serviço	Texto
<u>NCM</u>	Nomenclatura Comum do Mercosul	8 dígitos
<u>CFOP</u>	Código Fiscal de Operações	4 dígitos
<u>CST/CSOSN</u>	Código de Situação Tributária	2-3 dígitos
<u>vICMS, vIPI, vPIS, vCOFINS</u>	Valores dos Impostos	Numérico

Campo XML	Descrição	Validação
vBCICMS, pICMS	Base de Cálculo e Alíquota ICMS	Numérico

#### Workflow:

- 21 **Identificação e Validação:** Identifica se o input é um documento fiscal e valida campos críticos
- 22 **Extração de Dados:** Extrai campos fiscais estruturados do XML
- 23 **Criação de Chunks:** Cria chunks descritivos para embeddings
- 24 **Geração de Embeddings:** Vetoriza os chunks com FastEmbed
- 25 **Persistência:** Insere no Qdrant com metadata incluindo user\_id para isolamento

### 7.3. Data Analyst Agent - Análise Estatística

**Responsabilidade:** Especializado em realizar análises exploratórias de dados (EDA), gerar insights e criar visualizações (gráficos).

**Modelo LLM:** Llama 4 Maverick 17B (Groq) ou Gemini 2.5 Pro (Google)

**Ferramentas** (15+ ferramentas de análise):

- get\_data\_summary: Resumo estatístico do dataset
- create\_histogram: Histograma para colunas numéricas
- create\_bar\_chart: Gráfico de barras
- create\_scatter\_plot: Gráfico de dispersão
- create\_line\_chart: Gráfico de linhas
- create\_box\_plot: Box plot para detecção de outliers
- create\_correlation\_heatmap: Matriz de correlação
- detect\_outliers\_iqr: Detecção de outliers com IQR
- create\_cluster\_plot: Análise de clusters com K-Means
- python\_ast\_repl: Execução segura de código Python customizado

#### Workflow:

- 26 **Exploração:** Usa get\_data\_summary para entender a estrutura dos dados
- 27 **Planejamento:** Formula um plano de análise baseado na solicitação do usuário
- 28 **Seleção de Ferramenta:** Escolhe a ferramenta mais apropriada
- 29 **Execução:** Realiza a análise e gera visualizações
- 30 **Otimização:** Retorna apenas graph\_id e metadata (não o JSON completo do gráfico)

### 7.4. Tax Specialist Agent - Cálculos Fiscais

**Responsabilidade:** Especializado em recuperar dados do Qdrant e realizar cálculos e validações de impostos.

**Status:** Em desenvolvimento (estrutura criada)

**Funcionalidades Planejadas:**

- Recuperação de dados fiscais via busca semântica
- Cálculo de impostos (ICMS, IPI, PIS, COFINS)
- Validação de alíquotas aplicadas
- Detecção de inconsistências tributárias
- Simulação de cenários fiscais

## 7.5. Report Gen Agent - Geração de Relatórios

**Responsabilidade:** Criar documentos e relatórios profissionais em formato PDF e enviá-los por e-mail ao destinatário solicitado via SMTP.

**Modelo LLM:** Llama 3.3 70B Versatile (Groq) ou Gemini 2.5 Flash (Google)

**Ferramentas:**

- create\_and\_send\_report: Cria PDF a partir de Markdown e envia por e-mail via SMTP
- Validação de e-mail com regex
- Geração de PDF com markdown-pdf

**Workflow:**

- 31 **Estruturação:** Organiza o conteúdo do relatório em Markdown
  - 32 **Geração de PDF:** Converte Markdown para PDF com formatação profissional
  - 33 **Validação de E-mail:** Valida o endereço de e-mail do destinatário
  - 34 **Envio via SMTP:** Estabelece conexão SMTP e envia o relatório anexado
  - 35 **Confirmação:** Retorna status de sucesso ou erro detalhado
- 

## 8. Fluxos de Dados e Processos

### 8.1. Fluxo de Ingestão de Dados Fiscais

O processo de ingestão de documentos fiscais envolve múltiplas etapas de validação, extração e armazenamento vetorial.

**Etapas do Processo:**

- 36 **Recebimento do Documento:** Usuário envia XML de nota fiscal via frontend
- 37 **Roteamento pelo Supervisor:** Identifica como tarefa de extração e aciona Data Engineer
- 38 **Análise e Validação:** Data Engineer valida campos críticos (CNPJ, datas, valores)
- 39 **Extração de Dados:** Extrai campos fiscais e cria chunks descritivos
- 40 **Geração de Embeddings:** FastEmbed vetoriza os chunks com dimensionalidade de 384 posições.
- 41 **Armazenamento no Qdrant:** Insere vetores com metadata incluindo `user_id` para isolamento
- 42 **Confirmação:** Retorna IDs dos pontos inseridos e confirmação de sucesso

## 8.2. Fluxo de Busca Semântica (RAG)

A busca semântica permite que os usuários façam perguntas em linguagem natural e recebam respostas contextualizadas baseadas nos documentos fiscais armazenados.

### Etapas do Processo:

- 43 **Pergunta do Usuário:** "Quais foram as despesas com material de escritório em fevereiro?"
  - 44 **Análise pelo Supervisor:** Identifica necessidade de busca em dados fiscais
  - 45 **Acionamento do Tax Specialist:** Delega para o agente de cálculos fiscais
  - 46 **Extração de Dados:** Tax Specialist solicita busca ao Data Engineer
  - 47 **Vetorização da Query:** FastEmbed gera embedding da pergunta
  - 48 **Busca no Qdrant:** Busca ANN (HNSW) com filtro de `user_id` para isolamento
  - 49 **Cálculo de Similaridade:** Qdrant calcula distância cosine entre query e documentos
  - 50 **Retorno de Resultados:** Top 10 documentos mais similares com scores
  - 51 **Agregação e Análise:** Tax Specialist agrupa valores e gera insights
  - 52 **Resposta Contextualizada:** LLM gera resposta formatada com os dados encontrados
- 

## 9. Isolamento Multi-Tenancy e Segurança

A arquitetura multi-tenancy garante que os dados de cada usuário fiquem completamente isolados, permitindo que o ambiente seja seguro para múltiplos clientes sem risco de acesso indevido.

### 9.1. Implementação de Multi-Tenancy

#### Mecanismo de Isolamento:

- **Injeção de `user_id`:** Cada chunk de dados recebe automaticamente o ID da sessão no campo `metadata.user_id`.
- **Índice de Payload:** Campo `metadata.user_id` é indexado como `tenant` para otimização de performance de busca.
- **Filtros de Busca:** Todas as buscas incluem obrigatoriamente um filtro por `user_id`.
- **Validação de Acesso:** O sistema valida que o ID da sessão corresponde ao `user_id` dos dados.

## 9.2. Garantias de Segurança

Aspecto de Segurança	Implementação	Nível de Proteção
Isolamento de Dados	Filtro obrigatório por <code>user_id</code> em todas as buscas	✓ Alto
Validação de Entrada	Pydantic schemas em todos os endpoints	✓ Alto
Proteção contra Prompt Injection	Instruções de sistema com regras estritas	✓ Médio
Execução Segura de Código	AST REPL para código Python	✓ Alto
Validação de E-mail	Regex pattern matching	✓ Alto
SMTP Seguro	TLS/STARTTLS com autenticação	✓ Alto
Autenticação de Usuários	Não implementada	✗ Baixo
Rate Limiting	Não implementado	✗ Baixo


## 10. Resultados

Esta seção apresenta capturas de tela da plataforma em funcionamento, demonstrando as principais funcionalidades implementadas.

### 10.1. Interface Principal do Frontend

A interface principal da plataforma apresenta um design moderno e intuitivo, com navegação lateral e área de conversação com o agente.

Figura 3: Tela Principal da Plataforma SMART Financial Solutions]



### Características da Interface:

- Menu lateral com acesso a Dashboard, Novo Upload, Histórico e Configurações
- Área de status do processamento em tempo real
- Chat conversacional com o agente Smartie

## 10.2. Interação com o Agente e Extração de Dados Fiscais

O agente analista processa documentos fiscais e extrai informações estruturadas automaticamente.

Figura 4: Chat com Agente e Extração de Dados de Nota Fiscal]




### Funcionalidades Demonstradas:

- Status do processamento com etapas visuais
- Extração automática de campos fiscais (Emitente, Item, Valor total, Impostos)
- Resposta estruturada do agente com dados extraídos
- Interface de entrada para novas perguntas

### 10.3. Visualização de Gráficos Gerados

O Data Analyst Agent gera visualizações interativas utilizando Plotly.

*Figura 5: Gráfico de Histograma Gerado pelo Data Analyst Agent*



### Características das Visualizações:

- Gráficos interativos renderizados com Plotly.js na interface
- Modal de visualização externa para análise detalhada
- Botão para fechar e retornar ao chat

### 10.4. Configurações do Sistema

A página de configurações permite personalizar o comportamento da plataforma.

Figura 6: Página de Configurações do Sistema

The screenshot shows the configuration interface for an 'Agente Fiscal'. On the left, a sidebar lists navigation options: Dashboard, Novo Upload, Histórico, and Configurações (which is highlighted in blue). The main content area has two sections: 'Informações do Usuário' and 'Chaves de API'. The 'Informações do Usuário' section contains a form for entering an email address, which includes a purple asterisk icon indicating it's required. A blue 'Salvar' button is present. The 'Chaves de API' section contains a form for entering an API key, a dropdown menu for selecting a provider (set to 'Groq'), and a blue 'Salvar Chave' button.

**Agente Fiscal**

- Dashboard
- Novo Upload
- Histórico
- Configurações

**Configurações do Sistema**

**Informações do Usuário**

Email: \*

**Chaves de API**

Sua chave de API:

Insira sua chave secreta aqui...

Provedor: Groq

Salvar Chave

Powered by LangChain  
Favicon by Icons8

### Opções de Configuração:

- **Informações do Usuário:** Cadastro de e-mail para recebimento de relatórios
- **Chaves de API:** Configuração de chaves de acesso aos provedores de LLM (Groq, Gemini, OpenAI)
- **Seleção de Provedor:** Escolha do provedor de LLM preferido
- **Interface Intuitiva:** Ícones visuais e botões de ação claros

# 11. Referências Bibliográficas

## 11.1. Frameworks e Bibliotecas Principais

### Backend:

- 53 **FastAPI** (v0.119.0)  
Tiangolo, S. (2018). *FastAPI: High performance, easy to learn, fast to code, ready for production.*  
Disponível em: <https://fastapi.tiangolo.com/>
- 54 **LangChain** (v0.3.19)  
Chase, H. (2022). *LangChain: Building applications with LLMs through composability.*  
Disponível em: <https://python.langchain.com/>
- 55 **Qdrant** (Vector Database)  
Qdrant Team. (2021). *Qdrant: Vector Database for the next generation of AI applications.*  
Disponível em: <https://qdrant.tech/>
- 56 **FastEmbed**  
Qdrant Team. (2023). *FastEmbed: Lightweight, fast, Python library for embeddings.*  
Disponível em: <https://github.com/qdrant/fastembed>
- 57 **Pandas** (v2.3.2)  
McKinney, W. (2010). *Data Structures for Statistical Computing in Python.*  
Proceedings of the 9th Python in Science Conference, 56-61.
- 58 **Plotly** (v6.3.0)  
Plotly Technologies Inc. (2015). *Collaborative data science.*  
Disponível em: <https://plot.ly>
- 59 **SQLAlchemy** (v2.0.43)  
Bayer, M. (2006). *SQLAlchemy: The Database Toolkit for Python.*  
Disponível em: <https://www.sqlalchemy.org/>
- 60 **Pytesseract** (v0.3.13)  
Smith, R. (2007). *An Overview of the Tesseract OCR Engine.*  
Ninth International Conference on Document Analysis and Recognition (ICDAR 2007).
- 61 **Uvicorn** (v0.35.0)  
Encode. (2017). *Uvicorn: The lightning-fast ASGI server.*  
Disponível em: <https://www.uvicorn.org/>

### Frontend:

- 62 **React** (v18)  
Meta Platforms, Inc. (2013). *React: A JavaScript library for building user interfaces.*  
Disponível em: <https://react.dev/>
- 63 **TypeScript**  
Microsoft Corporation. (2012). *TypeScript: JavaScript with syntax for types.*  
Disponível em: <https://www.typescriptlang.org/>

#### 64 **Vite**

Evan You. (2020). *Vite: Next Generation Frontend Tooling*.  
Disponível em: <https://vitejs.dev/>

#### 65 **Plotly.js**

Plotly Technologies Inc. (2015). *Plotly.js: Open-source JavaScript charting library*.  
Disponível em: <https://plotly.com/javascript/>

### **Provedores de LLM:**

#### 66 **Google Gemini**

Google DeepMind. (2023). *Gemini: A family of highly capable multimodal models*.  
Disponível em: <https://deepmind.google/technologies/gemini/>

#### 67 **Groq**

Groq, Inc. (2023). *Groq: The fastest AI inference in the world*.  
Disponível em: <https://groq.com/>

#### 68 *OpenAI OpenAI*. (2023). *GPT-4 Technical Report*. Disponível em: <https://openai.com/research/gpt-4>

#### 69 **LangSmith**

LangChain, Inc. (2023). *LangSmith: The all-in-one developer platform for every step of the LLM-powered application lifecycle*.  
Disponível em: <https://www.langchain.com/langsmith>

## **11.2. Conceitos e Técnicas**

#### 70 **Bancos de Dados Vetoriais e Busca Semântica**Qdrant. (s.d.). **What is Qdrant?** In: Qdrant Documentation. Disponível em: <https://qdrant.tech/documentation/overview/>

#### 71 **Retrieval-Augmented Generation (RAG)**Qdrant. (s.d.). **Retrieval Augmented Generation (RAG)**. In: Qdrant Documentation. Disponível em: <https://qdrant.tech/documentation/tutorials/rag/>

#### 72 **HNSW Algorithm (Implementação de ANN)**Qdrant. (s.d.). **Indexing and Search**. In: Qdrant Documentation. Disponível em: <https://qdrant.tech/documentation/concepts/indexing/#hnsw>

#### 73 **Multi-Tenancy Architecture**Qdrant. (s.d.). **Multitenancy**. In: Qdrant Documentation. Disponível em: <https://qdrant.tech/documentation/guides/multitenancy/>

#### 74 **Embeddings and Sentence Transformers**Qdrant. (s.d.). **What are Vector Embeddings?** In: Qdrant Documentation. Disponível em: <https://qdrant.tech/documentation/concepts/vector-embeddings/>

## **11.3. Documentação Fiscal Brasileira**

#### 75 **Nota Fiscal Eletrônica (NF-e)**

Portal da NF-e. *Nota Fiscal Eletrônica*.  
Disponível em: <https://www.nfe.fazenda.gov.br/>

---

## 12. Conclusão

A aplicação **Smart Financial Solutions v2.0** representa um avanço significativo na gestão fiscal automatizada, combinando o poder da Inteligência Artificial com técnicas avançadas de **Retrieval-Augmented Generation (RAG)**. A integração do Qdrant Vector Database e a implementação do Data Engineer Agent especializado em documentos fiscais brasileiros posicionam a solução como uma ferramenta estratégica e de alto valor para empresas que buscam excelência em compliance e eficiência operacional.

### 12.1. Principais Conquistas

- **Arquitetura RAG Implementada:** Busca semântica em documentos fiscais com isolamento multi-tenancy
- **Data Engineer Agent:** Especialista em extração e validação de dados fiscais brasileiros
- **Validações Robustas:** Múltiplas camadas de validação garantem qualidade dos dados
- **Escalabilidade:** Arquitetura preparada para crescimento com Qdrant e FastAPI assíncrono
- **Segurança:** Isolamento completo de dados por usuário
- **Envio Automatizado de Relatórios:** Implementação SMTP nativa para envio de relatórios PDF

### 12.2. Diferenciais Competitivos

- 76 **Busca Semântica Inteligente:** Localização de informações fiscais por significado, não apenas por palavras-chave
- 77 **Especialização em Documentos Brasileiros:** Validação específica para NFe, CTe e outros documentos fiscais nacionais
- 78 **Multi-Tenancy Nativo:** Arquitetura preparada para SaaS desde o início
- 79 **Orquestração de Agentes:** Sistema multiagente com especialização clara de responsabilidades
- 80 **Extensibilidade:** Fácil adição de novos agentes e ferramentas

### 12.3. Impacto Esperado

A implementação completa da plataforma SMART v2.0, incluindo o Tax Specialist Agent planejado, tem potencial para:

- **Reducir em 90% o tempo de validação de documentos fiscais**
- **Eliminar 99% dos erros de digitação e extração de dados**
- **Acelerar em 75% os processos de auditoria interna**

- **Reducir em 60-70% os custos operacionais de gestão fiscal**
- **Aumentar a conformidade fiscal e reduzir riscos de multas**

A solução está **pronta para uso em ambiente de desenvolvimento e demonstração**, com uma base técnica sólida para evolução para produção em larga escala.

---

**Data de Elaboração:** 30 de Outubro de 2025

**Versão do Relatório:** 0.1

**Repositório:** [https://github.com/gabryel-barboza/smart\\_financial\\_solutions](https://github.com/gabryel-barboza/smart_financial_solutions)